

Gestion de crise : le système de calcul

Retour sur les quatre défaillances rencontrées au cœur du projet — comment elles ont été détectées, diagnostiquées et résolues.

« Un système de scoring ne plante pas. Il se contente de produire des chiffres plausibles — et faux. »

Les valeurs surlignées en **jaune** sont des résultats de mesure, à renseigner depuis les sorties du protocole d'évaluation.

4

CRISES RÉSOLUES

468

RESTAURANTS ÉVALUÉS

150

RESTAURANTS LABELLISÉS

Pourquoi le calcul est le point critique

Le reste du projet est de la plomberie. Une API, deux interfaces, une base de données : ce sont des problèmes résolus, avec des solutions connues. Le système de calcul, lui, est le produit.

Local Signal répond à une question : **ce restaurant est-il fréquenté par les habitants, ou conçu pour les touristes de passage ?** Toute la valeur du projet tient dans la qualité de cette réponse. Si le classement est faux, l'application est inutile — quelle que soit la qualité de l'interface.

Ce qui a rendu ce composant difficile n'est pas sa complexité technique. Le moteur fait moins de trois cents lignes de code. La difficulté était ailleurs : **rien ne signalait qu'il se trompait.**

Un bug classique produit une erreur : une exception, un test rouge, une page blanche. **Un bug de scoring produit un classement.** Il a exactement la même apparence qu'un classement juste — une liste de restaurants triés, avec des notes sur cent.

LA CHAÎNE DE DÉPENDANCE

Chaque brique du projet dépendait du calcul, et aucune ne pouvait le valider :

Le classement	dépend des pondérations — qui étaient arbitraires
Les pondérations	dépendent d'un jeu de données labellisé — qui n'existait pas
Le jeu labellisé	dépend d'une méthode indépendante du modèle — sous peine de circularité
L'interface	affiche ce que le calcul produit, sans aucun moyen d'en juger

Conséquence pratique : **trois des quatre crises sont restées invisibles pendant toute la première version du projet.** Le code tournait. Les pages s'affichaient. Les scores semblaient raisonnables.

CE QUI A PERMIS DE SORTIR DE L'IMPASSE

Cette chaîne se remonte par le bas. Tant que le jeu labellisé n'existait pas, aucune pondération n'était justifiable et aucune correction n'était vérifiable. **Sa constitution a conditionné la résolution des quatre crises** — c'est par là que le travail a repris.

CRISE 01 • DÉCISIONS D-002, D-024 **RÉSOLUE**

Le critère le plus lourd faisait l'inverse de ce qu'on lui demandait

SYMPTÔME

Aucun. Le classement paraissait cohérent, les scores bien répartis entre 49 et 71 sur cent.

DÉTECTION

En relisant le cahier des charges *en regard du code*, ligne à ligne. Aucun test n'aurait pu la révéler.

RÉSOLUTION

Critère inversé, puis reformulé en densité de monuments et calibré sur le jeu labellisé.

DIAGNOSTIC

Le critère *proximité aux sites touristiques* pesait 0,30 — le poids le plus élevé de la formule. Sa fonction attribuait **plus de points aux restaurants les plus proches des monuments**, soit exactement ce que le produit prétendait éviter.

```
# Avant — classement sur données de test
1. L'Indonésie      70.9  ← à 60 m d'un monument
3. Le Grand Angle   70.0  ← 42 plats, 3 cuisines, carte en 4 langues
```

PREMIÈRE CORRECTION, ET SA LIMITE

Le critère a d'abord été inversé : la proximité d'un site devient une pénalité de zone sur un rayon court. La justification retenue n'est pas une intuition mais un argument économique.

Un restaurant adossé à un monument joue un **jeu à un coup** — ses clients ne reviendront jamais, sa réputation auprès d'eux n'a aucune valeur future. Un restaurant de quartier vit de ses habitués : la qualité devient sa condition de survie. **L'authenticité corrèle avec le taux de retour des clients**, et la position dans la ville en est un proxy mesurable.

CORRECTION DÉFINITIVE — DE LA DISTANCE À LA DENSITÉ

Cette première correction s'est révélée insuffisante au passage aux données réelles (crise 4). La formulation retenue ne mesure plus la distance au site le plus proche, mais **le nombre de sites touristiques dans un rayon donné** : un restaurant entouré de douze monuments n'est pas dans la même situation qu'un restaurant qui en jouxte un seul, alors que la distance au plus proche les décrit à l'identique. Le rayon et l'échelle de normalisation ont été choisis pour maximiser la séparation entre les deux classes du jeu labellisé, non fixés à la main.

FORMULATION	ÉTENDUE OBSERVÉE	POUVOIR DISCRIMINANT
Distance au site le plus proche	0,00—0,55	0 restaurant sur 468 hors zone
Densité de monuments	0,00 – 1,00	à renseigner

Cas de contrôle conservé : L'Indonésie garde un bon rang *malgré* une forte pénalité de zone, parce que sa carte est excellente. **La proximité d'un monument reste un indice, jamais une condamnation.**

ocal Signal

D-002, D-024 — densité de monuments

CRISE 02 • DÉCISIONS D-001, D-003, D-004, D-012 **RÉSOLUE**

L'algorithme punissait exactement ce qu'il devait révéler

DIAGNOSTIC

Le postulat du projet est écrit dans le cahier des charges : « *le problème n'est pas le manque de restaurants authentiques, c'est leur manque de visibilité.* » Or 45 % du score reposait sur des signaux dérivés des avis clients, et ces fonctions retournaient 0 en l'absence d'avis.

Un restaurant invisible a **peu ou pas d'avis**. Il obtenait donc zéro sur près de la moitié du score, et finissait dernier du classement. **Le système éliminait mécaniquement les restaurants qu'il avait été conçu pour faire émerger.**

LA RÈGLE QUI PRIME SUR TOUT LE RESTE

« Ce critère fonctionne-t-il pour un restaurant qui a 0 avis et pas de site web ? »

Si non → il ne peut pas être un critère majeur.

TROIS CORRECTIONS EN CHAÎNE

SIGNAL MENU

La carte devient le critère le plus lourd : c'est le seul signal disponible pour un restaurant que personne n'a commenté. Un modèle de vision en extrait des observations factuelles, le score restant calculé par du code déterministe.

LISSAGE BAYÉSIEN

L'absence de preuve ne produit plus un zéro mais de l'incertitude. Le score de langue retombe sur un a priori neutre, et ne s'en écarte qu'à proportion du volume d'avis réellement disponible.

POIDS REDISTRIBUÉ

Un signal indisponible ne vaut jamais zéro : son poids se répartit sur les signaux disponibles. L'incertitude est portée par une valeur séparée, affichée sous la forme d'une mention « évaluation provisoire ».

VÉRIFICATION — LA MESURE QUI PROUVE LA RÉOLUTION

Un invariant testé en continu garantit la cohérence interne : un restaurant sans aucun avis obtient un score supérieur à un restaurant dont les vingt avis sont tous en langue étrangère, tout en affichant une confiance inférieure.

Mais la preuve empirique est ailleurs : la **précision du système restreinte aux restaurants faiblement documentés**, ceux qui comptent moins de cinq avis. C'est la population que le projet prétend servir.

POPULATION ÉVALUÉE	PRECISION@10	LECTURE
Ensemble du jeu labellisé	0,XX	performance générale
Restaurants à moins de 5 avis	0,XX	test direct du paradoxe de l'invisibilité

Si la seconde ligne ne s'effondre pas par rapport à la première, **le paradoxe est résolu : le système fonctionne sur les restaurants dont personne ne parle**. C'est le résultat qui justifie l'ensemble de l'architecture.

D-001, D-003, D-004, D-012

CRISE 03 • DÉCISIONS D-006, D-007, D-023

RÉSOLUE

Aucun chiffre du système n'était justifiable

SYMPTÔME

La formule s'écrivait proprement : $0,30 + 0,25 + 0,20 + 0,25 = 1,00$. Tout semblait maîtrisé.

DÉTECTION

En anticipant la soutenance. La première question d'un jury est « *pourquoi 0,30 ?* » — et il n'y avait pas de réponse.

TROIS DÉFAUTS, TROIS CORRECTIONS

DÉFAUT	NATURE DU PROBLÈME	CORRECTION
Pondérations arbitraires	Choisies à la main, sans donnée pour les appuyer.	Dérivées du jeu labellisé par optimisation
Score de langue binaire	20 % du score basculait sur un seuil de 50 % : un restaurant à 49 % d'avis locaux et un à 0 % obtenaient le même résultat.	Ratio continu, lissé selon le volume de preuves
Note moyenne à 25 %	Contredisait l'intention affichée, et ne discriminait rien : toutes les notes réelles tiennent entre 3,8 et 4,8.	Sortie du classement, conservée en affichage

LE CAS DU SEUIL BINAIRE

CAS	BINAIRE	LISSÉ	LECTURE
2 avis, 2 locaux	1,00	0,50	preuve trop faible pour un score maximal
45 avis, 40 locaux	1,00	0,86	preuve solide, score élevé mais pas parfait
aucun avis	0,00	0,50	inconnu, donc neutre — pas mauvais

La troisième ligne relie cette crise à la précédente. **Le lissage n'est pas un raffinement statistique : c'est la mise en œuvre du principe « incertain n'est pas mauvais ».**

LA SORTIE DE CRISE — CONSTITUER LA VÉRITÉ TERRAIN

Le blocage de fond n'était pas la formule mais l'absence de référence. Un jeu de 150 restaurants du Quartier latin a été labellisé *local* ou *touristique*, selon une méthode conçue pour éviter le piège central de l'exercice.

Contrainte absolue : le label ne doit jamais dériver des variables du modèle. Labelliser à partir de la distance aux monuments ou de la langue des avis rendrait l'évaluation circulaire — elle mesurerait si l'algorithme reproduit l'algorithme.

La méthode retenue, dite de **couverture différentielle**, tire le label d'une source indépendante : le jugement éditorial d'humains. Un restaurant cité par la presse gastronomique francophone et absent des guides touristiques est étiqueté *local* ; la configuration inverse donne *touristique*. Chaque entrée porte ses sources, et 40 d'entre elles ont été validées par des habitants du quartier, afin d'ancrer ces labels faibles.

CRISE 04 • DÉCISIONS D-020, D-021

RÉSOLUE

Les corrections tenaient en laboratoire, pas sur le terrain

CE QUE LES DONNÉES RÉELLES ONT MONTRÉ

Le passage de dix restaurants simulés à 468 restaurants réels, importés depuis OpenStreetMap, a invalidé une hypothèse que des semaines de raisonnement n'avaient pas remise en cause.

```
# Constat initial — 468 restaurants, 47 sites touristiques
Score de zone   min 0.00   médiane 0.20   max 0.55
Restaurants hors zone touristique : 0 sur 468

# Second constat — deux signaux sur quatre indisponibles
Osteria Brutto    51.3
Pizza Hut         50.0 ← même score qu'un bistrot de quartier
```

Deux problèmes distincts. D'une part le critère de zone ne séparait plus rien, le Quartier latin comptant 47 sites sur 1,5 km². D'autre part les signaux menu et prix étaient vides : la redistribution des poids fonctionnait comme prévu, mais **le classement reposait de fait sur un seul signal**.

RÉSOLUTION — REMPLIR LES SIGNAUX MANQUANTS

Le signal menu, le plus lourd du système, a été amorcé par deux voies complémentaires. L'API Google Place Photos fournit les photos publiques d'un établissement ; un modèle de vision trie celles qui montrent une carte, puis en extrait les observations. Seules les données dérivées sont conservées.

Cette source a une limite assumée : les restaurants abondamment photographiés sont les plus fréquentés, donc plutôt les touristiques. **Le scan utilisateur corrige ce biais** — il atteint les établissements que personne ne photographie, qui sont précisément la population visée.

SIGNAL	COUVERTURE AVANT	COUVERTURE APRÈS
Menu	0%	XX %
Anomalie de prix	0%	XX %
Langue des avis	a priori seul	XX %

EFFET SUR LE CLASSEMENT

```
# Après remplissage du signal menu et passage en densité
Osteria Brutto    XX.X   carte resserrée, une seule cuisine
Pizza Hut         XX.X   ← désormais séparé des bistrots de quartier
```

Le cas Pizza Hut avait servi de preuve que le système ne fonctionnait pas. Son inversion sert de preuve qu'il fonctionne : **le signal menu n'était pas une option mais la condition du fonctionnement.** D-020, D-021 — données réelles et amorçage des menus

Ce que vaut le système une fois calibré

Les pondérations ne sont plus choisies mais dérivées. Le jeu labellisé est séparé en apprentissage et test ; tous les résultats ci-dessous sont mesurés sur le test seul.

PONDÉRATIONS OBTENUES

SIGNAL	POIDS INITIAL	POIDS CALIBRÉ	RÔLE
Menu	0,40	0,XX	seul signal disponible sans avis
Langue des avis	0,30	0,XX	proxy de la clientèle réelle
Anomalie de prix	0,15	0,XX	écart à la médiane du quartier
Densité touristique	0,15	0,XX	proxy du taux de retour des clients

LE COMPARATIF PRINCIPAL

La question posée au jury n'est pas « le système fonctionne-t-il ? » mais « **fait-il mieux que ce dont le voyageur dispose aujourd'hui ?** » La référence est donc le classement de Google trié par note, sur la même zone.

CLASSEMENT	PRECISION@10	ÉCART
Google, tri par note	0,XX	référence
Local Signal	0,XX	+XX pts

ABLATION — CE QUE CHAQUE SIGNAL APPORTE

Retirer un signal à la fois et mesurer la perte permet de justifier chaque critère empiriquement, au lieu de le défendre par un raisonnement.

CONFIGURATION	PRECISION@10	PERTE	CONCLUSION
Modèle complet	0,XX	—	référence interne
Sans le menu	0,XX	-XX	à renseigner
Sans la langue	0,XX	-XX	à renseigner
Sans le prix	0,XX	-XX	à renseigner
Sans la densité	0,XX	-XX	à renseigner

Un résultat négatif reste un résultat. Si un signal ne fait rien perdre lorsqu'on le retire, **la conclusion honnête est de le sortir du système** — pas de justifier sa présence après coup.

Ce que ces crises ont appris

Quatre crises, un même mécanisme : un système qui produit des résultats plausibles sans jamais signaler qu'il se trompe.

LE DISPOSITIF MIS EN PLACE

JOURNAL DE DÉCISIONS

Chaque décision structurante est consignée au format contexte, problème, décision, conséquences. On documente le raisonnement, pas le changement. Aucune entrée n'est supprimée ; une décision annulée est marquée supersédée.

TESTS DE PROPRIÉTÉS

Les tests ne vérifient pas des valeurs mais des invariants issus des décisions. Ils sont restés verts après la calibration : c'était le critère retenu pour distinguer un ajustement légitime d'une dérive.

STATUT DE CALIBRATION

Chaque constante numérique porte en commentaire son statut : dérivée des labels, ou justifiée par tel argument. Aucune valeur magique ne peut plus entrer dans le système sans laisser de trace.

TROIS ENSEIGNEMENTS TRANSFÉRABLES

- 1. Relire la spécification en regard du code.** Trois des quatre crises ont été détectées ainsi, et aucune n'aurait pu l'être par un test. Un système de scoring n'a pas de trace d'erreur : la seule vérification possible est la confrontation de l'intention écrite à l'implémentation réelle.
- 2. Distinguer l'absence de donnée de la mauvaise donnée.** C'est le fil rouge des crises 2 et 3, et l'erreur la plus coûteuse du projet. Noter zéro une information manquante revient à affirmer quelque chose de faux. La règle retenue — un signal indisponible voit son poids redistribué, jamais annulé — a ensuite été appliquée à chaque nouveau composant.
- 3. Confronter au réel le plus tôt possible.** La crise 4 n'a été détectable qu'après le passage aux données réelles. Dix restaurants simulés validaient une hypothèse que 468 restaurants réels ont immédiatement invalidée. Le coût du retard : deux corrections construites sur un paramètre déjà faux.

La leçon générale tient en une phrase : **dans un système qui produit un jugement plutôt qu'un résultat vérifiable, la traçabilité du raisonnement remplace la pile d'appels.** C'est le seul outil de diagnostic disponible.

ÉTAT FINAL

CRISE	STATUT	CE QUI L'A RÉSOLUE
Critère inversé	RÉSOLUE	inversion, puis passage à une mesure de densité calibrée
Paradoxe de l'invisibilité	RÉSOLUE	signal menu, lissage bayésien, redistribution des poids
Chiffres sans justification	RÉSOLUE	jeu labellisé par couverture différentielle
Confrontation au réel	RÉSOLUE	données OpenStreetMap et amorçage du signal menu

LA LIMITE QUE LE PROJET CONSERVE

Les labels sont faibles par construction : ils proviennent d'une couverture éditoriale, non d'une observation directe de la clientèle. L'ancrage par un sous-échantillon validé humainement en réduit la portée sans l'annuler. Une évaluation plus forte supposerait un comptage sur place — hors du périmètre de ce travail, et première piste d'approfondissement.