

Local Signal

Note de synthèse pour l'équipe — état au 4 septembre 2026

1. Le projet en une phrase

Aider un voyageur qui ne connaît pas une ville à trouver un **vrai restaurant local** plutôt qu'un attrape-touristes, en calculant un score d'authenticité mesurable.

Question de recherche : peut-on mesurer automatiquement l'authenticité locale d'un restaurant *sans se reposer sur sa popularité* ?

La contrainte qui commande tout — le paradoxe de l'invisibilité. Le problème n'est pas le manque de restaurants authentiques, c'est leur manque de visibilité. Un restaurant invisible a peu ou pas d'avis. Donc **tout critère qui dépend du volume d'avis ou de la notoriété disqualifie mécaniquement les restaurants que le projet veut mettre en avant.**

Conséquence directe : les *étoiles Google ne participent pas au classement*. Elles sont en base, elles s'affichent, elles ne notent pas.

2. La formule

LOCAL SIGNAL (statique, précalculé, stocké en base)
= menu 0,40 + langue 0,30 + prix 0,15 + zone touristique 0,15

CLASSEMENT (dynamique, calculé à chaque requête)
= local_signal × 0,70 + proximité × 0,30

Pourquoi deux étages

Le **Local Signal** décrit ce qu'est le restaurant : il ne dépend pas de qui cherche, il se calcule une fois en lot et se stocke. La **proximité** décrit ce qui *arrange* l'utilisateur ici et maintenant.

Deux bénéfices : l'application reste instantanée même avec 50 000 restaurants, et l'explication rendue à l'utilisateur parle du restaurant, pas de sa position.

Les quatre indicateurs

Indicateur	Poids	Ce qu'il mesure	Pourquoi il résiste au paradoxe
menu	0,40	cohérence culinaire, nombre de plats, langues, noms conservés en langue d'origine	lisible même avec zéro avis — c'est le seul signal d'un restaurant totalement invisible
langue	0,30	part des avis rédigés en langue locale, <i>lissée</i>	lissage bayésien : peu d'avis ne pénalise pas, ça réduit la confiance
prix	0,15	écart à la médiane du voisinage, à cuisine comparable	relatif au quartier, pas absolu
zone touristique	0,15	pression touristique du lieu — <i>pénalité</i>	propriété du lieu, indépendante de la notoriété du restaurant

Trois règles de calcul à connaître

1. **Un indicateur indisponible rend *None*, jamais 0.** Le moteur redistribue son poids sur les autres. L'incertitude va dans la *confiance*, pas dans le score. Un restaurant sans carte n'est pas « mauvais », il est « moins bien renseigné ».
2. **Tout indicateur rend une valeur entre 0 et 1.** La pondération et la mise à l'échelle sur 100 n'ont lieu qu'à un seul endroit.
3. **Le modèle observe, il ne juge pas.** On ne demande jamais à une IA « ce restaurant est-il authentique ? ». Elle relève des faits ; le score est calculé par du code déterministe. C'est ce qui le rend reproductible, explicable et calibrable.

3. Les scores géographiques, formule par formule

Ils ont été refondus le 2 septembre après mesure sur les données réelles. Les deux formules initiales reposaient sur des seuils en mètres choisis à vue, et les données ont montré qu'ils ne mordaient nulle part.

Quatre objets mathématiques standards s'enchaînent ici. Aucun n'est inventé pour le projet, et c'est délibéré : devant un jury, une méthode qui porte un nom et une littérature se défend, une formule maison se discute.

Étape	Nom scientifique	Rôle ici
Distance	Formule de haversine <i>haversine formula — distance orthodromique</i>	distance sur la sphère entre deux points GPS
Pression	Estimation par noyau gaussien <i>Gaussian kernel density estimation (KDE)</i>	agrège l'effet de tous les monuments en un champ continu
Score	Rang en percentile <i>empirical CDF — probability integral transform</i>	rend le résultat sans unité, donc transportable d'une ville à l'autre
Proximité	Décroissance exponentielle de la distance <i>negative exponential distance-decay / deterrence function</i>	traduit une distance en préférence, sans seuil
Agrégation	Moyenne arithmétique pondérée <i>weighted arithmetic mean — linear aggregation</i>	combine les quatre indicateurs en un seul nombre

3.1 Distance — formule de haversine

$$a = \sin^2(\Delta\phi/2) + \cos \phi_1 \cdot \cos \phi_2 \cdot \sin^2(\Delta\lambda/2)$$
$$d = 2R \cdot \operatorname{atan2}(\sqrt{a}, \sqrt{1-a}) \quad R = 6\,371\,000 \text{ m}$$

Nom : *formule de haversine*, d'après la fonction $\operatorname{hav}(\theta) = \sin^2(\theta/2)$. Elle donne la *distance orthodromique* — la longueur de l'arc de grand cercle entre deux points d'une sphère.

Pourquoi elle et pas une autre. Une distance euclidienne calculée sur latitude/longitude est fausse dès qu'on quitte l'équateur : un degré de longitude vaut 111 km à l'équateur et 74 km à Paris. Haversine reste numériquement stable sur les petites distances, là où la loi des cosinus sphérique perd sa précision par arrondi. Son erreur vient de l'hypothèse sphérique — la Terre est un ellipsoïde — soit environ 0,3 % au pire ; sur 200 m, 0,6 m, sans conséquence pour un classement. La formule de Vincenty, exacte sur l'ellipsoïde, coûterait bien plus cher pour un gain nul ici.

3.2 Pression touristique — estimation par noyau (statique)

$$\text{pression}(r) = \sum_i \exp(-d_i^2 / 2\sigma^2) \quad \text{sur TOUS les sites, } \sigma = 350 \text{ m}$$

Nom : *estimation par noyau gaussien* (Gaussian kernel density estimation, KDE). En statistique spatiale, c'est l'*estimateur à noyau de l'intensité d'un processus ponctuel* : les monuments sont les points, la pression est l'intensité du champ qu'ils engendrent. C'est exactement ce qu'un SIG appelle une *carte de chaleur*. Le noyau gaussien est aussi la *fonction à base radiale* (RBF) la plus courante.

σ s'appelle la largeur de bande (bandwidth, ou fenêtre de lissage). C'est l'unique paramètre de la méthode, et le dernier endroit où une valeur en mètres subsiste. À $\sigma = 350$ m, un monument pèse 0,61 à 350 m, 0,14 à 700

m, 0,01 à 1 050 m : son influence s'éteint sans jamais être coupée net. La valeur correspond à environ cinq minutes de marche — **elle est posée, pas calibrée**, et devra l'être sur le jeu labellisé.

Le noyau n'est pas normalisé. Il manque le facteur $1/(\sigma\sqrt{2\pi})$ de la densité gaussienne. C'est volontaire : le rang en percentile qui suit est invariant par toute transformation croissante, donc multiplier la pression par une constante ne change rien au score. L'écrire aurait coûté un calcul et suggéré une précision qui n'existe pas.

Pourquoi une somme, et non « la distance au monument le plus proche ». Mesuré sur les 468 restaurants du Quartier latin : à distance comparable du monument le plus proche (60–70 m), la pression réelle varie de 4,99 à 20,86 — un facteur 4 que « distance au plus proche » écrase intégralement. Un restaurant cerné par douze monuments ne subit pas le flux d'un restaurant qui en a un seul à la même distance. Et le seuil de 500 m ne servait à rien : la distance médiane au monument le plus proche est de 102 m, le maximum de 273 m. **Aucun** des 468 ne l'atteignait — la branche « hors zone » était du code mort, et le score plafonnait à 0,55 au lieu de 1,00.

```
score_zone(r) = 1 - rang_percentile( pression(r) )    dans la cohorte
```

Nom : rang en percentile — l'application de la *fonction de répartition empirique* (empirical CDF) à sa propre distribution. La statistique nomme cette opération *transformation intégrale de probabilité* : elle transforme n'importe quelle distribution en une loi uniforme sur [0, 1]. Les égalités sont traitées par *rang moyen* (midrank), pour que deux pressions identiques donnent deux scores identiques — sinon l'ordre d'itération déciderait du classement.

Pourquoi un rang et non un seuil. Aucune constante en mètres ne survit à un changement de ville : 500 m calibrés sur le Quartier latin seraient faux à Tokyo comme dans un village. Un rang n'a pas d'unité. La propriété exacte s'appelle l'*invariance par transformation monotone croissante*, et elle est vérifiée par un test : *multiplier toutes les distances par 10 ne change pas le classement*. Second effet : l'étendue 0–1 est garantie par construction, là où l'ancienne formule n'atteignait jamais que 0,55.

Ce que ce choix coûte, et qu'il faut assumer. Le score devient *relatif à la cohorte*. Il répond à « ce restaurant est-il dans un coin touristique *de cette ville* », pas à « cette ville est-elle touristique ». Deux villes ne sont plus comparables sur ce signal. C'est pourquoi la pression absolue — elle, dimensionnée et comparable — est **conservée séparément en base** : c'est elle qui servira à la calibration et à toute comparaison entre villes.

Le rang est calculé **en lot**, jamais dans le chemin d'une requête : le signal reste statique au sens de la séparation §2, et deux requêtes différentes ne peuvent pas attribuer deux scores au même restaurant.

3.3 Proximité utilisateur — décroissance exponentielle (dynamique)

```
score_prox(r) = exp( -d / (rayon demandé × 0,5) )
```

Nom : fonction de décroissance exponentielle de la distance (negative exponential distance-decay). En économie spatiale et dans les modèles gravitaires, c'est la *fonction de dissuasion* (deterrence function) de forme $\exp(-\beta d)$, où β est le *paramètre de décroissance*. Ici $\beta = 1 / (\text{rayon} \times 0,5)$.

Lecture concrète du paramètre. La quantité $\text{rayon} \times 0,5$ est la *distance caractéristique* (e-folding distance) : celle où le score tombe à $1/e \approx 0,37$. Au bord du rayon demandé, le score vaut $e^{-2} \approx 0,14$. Sur une recherche à 800 m : 0,37 à 400 m, 0,14 à 800 m. La décroissance est donc franche à l'intérieur même de la zone cherchée, et c'est le but.

Pourquoi normalisé sur le rayon demandé. L'ancienne version divisait par 5 km fixes. Sur une recherche à 400 m, toutes les proximités tombaient entre 0,921 et 0,980 : une dispersion de 0,06 — **le terme ne départageait plus rien**, alors qu'il pèse officiellement 30 %. Normaliser sur le rayon rend la formule *auto-adaptative* : elle départage aussi bien une recherche de quartier qu'une recherche à l'échelle d'une ville, sans constante à retoucher.

Pourquoi exponentielle et pas linéaire. Une décroissance linéaire traiterait l'écart 100 m → 200 m comme l'écart 700 m → 800 m. La préférence réelle ne fonctionne pas ainsi : doubler une distance courte compte beaucoup, allonger une distance déjà longue compte peu. L'exponentielle est la seule fonction dont le taux de décroissance *relatif* est constant, ce qui est précisément cette propriété.

Nuance de vocabulaire, à connaître si on vous interroge. Un *poids* porte sur la valeur ; une *part de variance* dépend en plus de la dispersion du terme. Un poids de 0,30 ne promet pas 30 % de la variation du classement. Le défaut corrigé n'était pas « le poids ment » mais « le terme ne varie plus ». Un indicateur à faible *dispersion* contribue peu au classement quel que soit son poids nominal : c'est un résultat classique de l'*analyse de sensibilité* des indicateurs composites (Handbook OCDE-JRC, 2008).

3.4 Comment les quatre indicateurs sont agrégés

Local Signal = $(\sum w_i \cdot x_i) / (\sum w_i)$ sur les seuls indicateurs disponibles
confiance = $\sum w_i$ (à part, non mélangée au score)

Nom : *agrégation linéaire par moyenne arithmétique pondérée* (weighted arithmetic mean, linear aggregation) — la forme la plus courante d'indicateur composite, et celle que documente le Handbook OCDE-JRC. La division par la somme des poids *disponibles* s'appelle une *renormalisation des poids* ; l'approche générale, face aux données manquantes, est l'*analyse des cas disponibles* (available-case analysis).

C'est la traduction mathématique de la règle §2 : un indicateur absent rend **None**, il sort de la somme, et son poids se redistribue sur les autres au prorata. Le score reste sur la même échelle ; c'est la **confiance**, calculée à part, qui porte l'information « on en sait moins sur ce restaurant ». **L'absence n'est jamais convertie en mauvaise note** — sans quoi les restaurants les moins documentés, c'est-à-dire exactement ceux que le projet veut faire remonter, seraient pénalisés par leur invisibilité même.

Limite connue de cette forme, à assumer : l'agrégation linéaire est **entièrement compensatoire** — une très bonne carte peut masquer une très mauvaise note de prix. Les alternatives non compensatoires (moyenne géométrique, agrégation multicritère ordinale) sont documentées ; on ne les tranchera qu'après la calibration, faute de quoi on empilerait un second choix arbitraire sur le premier.

4. État actuel — Quartier latin, zone témoin

Indicateur	Poids	Couverture	État
menu	0,40	338 / 468 — 72 %	actif
langue	0,30	468 / 468	constante — sans effet
prix	0,15	278 / 468 — 59 %	actif
zone touristique	0,15	468 / 468	actif

70 % du poids de la formule est réellement actif. Le Local Signal s'étale de 33,5 à 81,4 ; la confiance médiane est de 0,70.

L'indicateur langue est inerte, et il faut savoir l'expliquer. Il mesure la part des avis rédigés en langue locale. Or nous avons le *nombre* d'avis, jamais leur *texte* — et on ne peut pas déduire une langue d'un décompte. Le lissage bayésien rend donc l'a priori neutre (0,50) pour tout le monde. Ce n'est pas un défaut de la formule : c'est un manque de données. 30 % du poids ne départage personne aujourd'hui.

5. La base

Contenu	Volume	Source
Restaurants, Paris entier	10 218	OpenStreetMap
Restaurants, Quartier latin (zone témoin)	468	OpenStreetMap
Sites touristiques	677	OpenStreetMap
Cartes lues et structurées	364	photos + sites web
Labels humains (vérité terrain)	0	à produire

SQLite en développement, PostgreSQL + PostGIS en cible. **Aucune image n'est conservée** : les photos de cartes sont analysées puis détruites, seules les observations dérivées et le texte relevé entrent en base.

6. Comment les cartes ont été obtenues

Quatre voies ont été essayées. Les rendements sont mesurés, pas estimés.

Voie	Rendement	Verdict
Tag OpenStreetMap <code>website:menu</code>	0 / 468	vide à l'échelle du quartier
Balimage <code>schema.org hasMenu</code>	1 / 18	les petits restaurants ne balisent pas
Sites web des restaurants	27 / 153	17,6 % — chaque site est construit autrement
API officielle de la plateforme	—	aucun champ menu, photos sans catégorie
Photos de carte via collecteur tiers	334 / 468	71 % — voie retenue

La lecture se fait **entièrement en local** : OCR hors ligne, puis un modèle de langue exécuté sur la machine. Ni quota ni facture. Les 312 cartes ont été lues en 37 minutes.

Quatre des six observations ne passent par aucun modèle — le nombre de plats est compté par expression régulière, donc reproductible à l'identique d'une lecture à l'autre. Seules la cuisine et le ratio vernaculaire demandent une compréhension du sens.

7. Ce qu'il faut répondre si on vous interroge

D'où viennent les données de cartes ?

Les restaurants et les sites touristiques viennent d'OpenStreetMap, en accès libre. Les cartes proviennent de photos publiées sur une plateforme cartographique, obtenues via un fournisseur commercial d'accès aux données. **Aucune image n'est conservée** : elles sont analysées puis détruites, seules les observations dérivées entrent en base. L'usage est strictement académique et non commercial, validé par le directeur de mémoire, et le cheminement complet est documenté dans le journal de décisions du projet.

Est-ce légal ?

C'est une zone grise assumée et documentée, pas une certitude. Le fournisseur obtient ces données par moissonnage, ce que les conditions d'utilisation de la plateforme interdisent — ces conditions lient le fournisseur, pas nous. Le droit européen prévoit une exception de fouille de textes et de données pour la recherche ; son application à un mémoire d'école n'est pas tranchée. La position du projet est la transparence : source documentée, images non conservées, finalité non commerciale. **Le jour où le projet devient commercial, cet argument tombe** — c'est pourquoi tout le code concerné est isolé dans un module supprimable sans casser le reste.

Pourquoi ne pas utiliser les notes et les avis, qui sont plus simples ?

Parce que ce serait refaire Google. Un restaurant de quartier a peu d'avis : tout critère fondé sur leur volume le condamne mécaniquement. C'est la thèse même du mémoire. Les notes sont stockées et affichées, elles ne notent pas.

D'où viennent les pondérations 0,40 / 0,30 / 0,15 / 0,15 ?

Elles sont provisoires, et il faut le dire. Elles n'ont pas encore été dérivées d'un jeu labellisé. Ne jamais les présenter comme justifiées. C'est précisément le chantier qui reste.

Comment savez-vous que le score fonctionne ?

Nous ne le savons pas encore. Une validation externe a été tentée en comparant le score aux restaurants que la plateforme marque « touristiques » : le résultat est *négatif*, mais confondu — les 21 restaurants du groupe témoin ne sont pas des adresses locales, ce sont des établissements peu connus sur lesquels la plateforme manque d'information. **Seule une vérité terrain humaine peut trancher.**

Quel est le biais connu du jeu de données ?

Il est mesuré : les restaurants marqués touristiques ont une carte disponible dans **91 %** des cas, contre **67 %** pour les autres. L'indicateur qui pèse le plus est donc mieux renseigné chez ceux que le projet veut déclasser. C'est le paradoxe de l'invisibilité qui revient par la porte des données, et il doit figurer dans le mémoire.

8. Ce qui reste à faire

Chantier	Nature	Bloque quoi
Vérité terrain — 150 à 300 restaurants labellisés	humain, long	tout le reste
Calibrer les pondérations sur ces labels	calcul	la défense des chiffres
Évaluation <code>precision@10</code> contre le top 10 par note	calcul	le résultat principal du mémoire
Débloquer l'indicateur langue	collecte	30 % du poids
Scan en vitrine dans l'application	code	les 112 restaurants sans aucune carte

La vérité terrain est la priorité absolue. Sans elle, aucune pondération n'est défendable et aucun résultat n'est démontrable. C'est du temps humain, pas du temps machine : elle doit démarrer en parallèle du reste, pas après.

Local Signal — projet de mémoire HETIC, destiné à être poursuivi comme produit.

Toutes les décisions structurantes sont consignées dans `docs/DECISIONS.md` au format contexte → problème → décision → conséquences (33 entrées).

Les chiffres de cette note sont mesurés sur les données réelles du Quartier latin au 4 septembre 2026. Les pondérations restent provisoires.